

딥러닝 기반 미국 증시 심리지표
분석 플랫폼

2025년

안양대학교 스마트창의융합대학
컴퓨터공학과
장 성 준

지 도 교 수 이 상 홍

이 논문을 공학 학사 학위논문으로 제출함.

2025년 12월

안양대학교 스마트창의융합대학

컴퓨터공학과

장 성 준

논문인준서

이 논문을 장성준의 공학 학사 학위논문으로 인준함.

2025년 12월

주 심 박 성 순 인

부 심 하 성 민 인

부 심 이 상 홍 인

차 례

요약	1
제 1장 서론	2
제 1절 배경	2
제 2장 관련 연구	3
제 1절 금융 텍스트 감정 분석과 심리지표 연구 동향	3
제 3장 연구 방법	5
제 1절 데이터셋 구성 및 전처리	5
제 2절 모델 아키텍처 및 학습 방법	7
제 3절 시장 심리지표 산출 방법	10
제 4장 시스템의 구현	13
제 1절 시스템 구현 환경	13
제 2절 Flutter 애플리케이션 구현	15
제 3절 구현 결과	18
제 5장 실험 결과 및 분석	
제 1절 모델 성능 평가	22
제 2절 시장 심리지표 검증	25
제 6장 결론 및 기대효과	27
제 1절 결론	27
제 2절 향후 과제	28
[참고 문헌]	29

표 및 그림 차례

표 차례

[표 1] 데이터셋 라벨링 분포	5
[표 2] 텍스트 길이 분포	6
[표 3] 모델 아키텍처 상세 (Batch Size 64 Baseline)	7
[표 4] 하이퍼파라미터 설정	7
[표 5] 학습 환경	8
[표 6] 배치 크기 별 K-Fold Cross-Validation 학습 시간	9
[표 7] 시장 심리지표 가중치	12
[표 8] Market Sentiment Index 범위 설정	12
[표 9] 배치 크기별 평균 성능 비교	22
[표 10] 배치 크기별 K-Fold Cross Validation 최종 결과	23
[표 11] 배치 사이즈 32, 64 Fold별 Confusion Matrix	24
[표 12] 동행성 검증 결과 요약	26

그림 차례

[그림 1] 데이터셋 텍스트 길이 분포 히스토그램	6
[그림 2] 시스템 아키텍처	14
[그림 3] market_sentiment_index 테이블	15
[그림 4] news_sentiment 테이블	16
[그림 5] 홈 탭 화면 1	18
[그림 6] 홈 탭 화면 2	18
[그림 7] 뉴스 탭 화면 1	19
[그림 8] 뉴스 탭 화면 2	19
[그림 9] 게시글 탭 화면	20
[그림 10] 프로필 탭 화면	20

[그림 11] 계정 설정 화면	21
[그림 12] 회원가입 화면	21
[그림 13] S&P 500과 시장 심리지표 피어슨 상관관계	25
[그림 14] 시장 심리지표와 S&P 500 변화율 동행성 비교	26

요 약

기존 시장 심리지표는 변동성 지수(VIX), 거래량, 풋 및 콜 비율 등 정형 데이터에만 의존하여 시장의 정서적 흐름을 충분하게 반영하지 못하는 한계를 지닌다. 그러나, 실제 투자자의 심리와 감정은 뉴스 제목 및 본문, 소셜 미디어 게시글 등 비정형 데이터 속에 더 풍부하게 내재되어 있다. 이에 본 연구는 정형 데이터의 정량적 분석력과 비정형 데이터의 질적 해석력을 통합하여 시장 심리를 정교하게 반영하는 접근 방식을 제시한다. 이를 통해 전통적인 금융 지표가 포착하지 못한 ‘감정적 요인’을 정량화하고, 투자자의 인지 편향과 시장의 군집 행동을 실시간으로 탐지할 수 있는 기반을 마련하고자 한다.

연구의 목적은 미국 증시 뉴스 및 비정형 금융 텍스트 데이터를 분석하고 이를 기술적 지표와 같은 정형 데이터와 융합하여 실시간으로 투자자 심리를 수치화하는 시장 심리지표(Market Sentiment Index)를 개발 및 검증하는 것이다. 이를 위해 딥러닝 기법 중 하나인 양방향 LSTM(Bidirectional Long Short-Term Memory)모델을 적용하여 문장을 긍정·중립·부정으로 분류하는 1차 정제를 거친다. 이후 도출된 감정 지수는 RSI, MACD, 이동평균선, VIX의 기술적 지표가 결합되는 2차 정제를 거쳐 통합된 심리지표로 합산된다. 뉴스 감정(0.35), RSI(0.15), VIX(0.15), MACD(0.15), 이동평균선(0.20)의 가중 평균을 통해 산출된 지표는 0에서 100 사이의 수치로 정규화되어, 시장이 Distressed-Neutral-Overheated의 다섯 구간 중 어느 상태에 위치하고 있는지 실시간으로 표현한다. 2차 정제된 데이터는 Flutter 기반 Application을 통해 사용자에게 시각적으로 전달되며, 투자자가 시장 심리를 직관적으로 이해하고 의사결정에 활용할 수 있도록 설계되었다.

모델의 평균 검증 정확도는 평균 91.04%로 높은 정확도를 보였으며, 미국 대표 지수인 S&P 500과 심리지표의 피어슨 상관계수는 0.888로 강한 양의 상관관계를 나타냈다. 또한, 동행성 검증에서도 84.91%가 일치하면서 시장의 정서적 흐름을 반영함을 입증하였다.

제 1장 서 론

제 1절 배경

현재 널리 사용되는 대표적인 시장 심리지표인 CNN의 공포·탐욕 지수(Fear and Greed)는 변동성 지수, 거래량, 풋 및 콜 옵션 등과 같은 정형 데이터를 기반으로 시장 심리지표를 수치화한다. 이러한 보조지표는 일정 수준의 직관적 통찰을 제공하지만, 금융 환경의 급변성과 정보 흐름의 실시간성을 반영하기에는 구조적 한계를 가진다. 특히 시장의 정서적 흐름은 뉴스 기사, 블로그, 커뮤니티 게시물 등과 같은 비정형 데이터 속에서 훨씬 더 풍부하게 드러나며 [1], 기존 지표들은 이를 충분히 포착하지 못하고 있다.

현대의 금융시장은 경제 지표뿐 아니라 뉴스, 소셜미디어, 온라인 커뮤니티 등에서 발생하는 여론과 감정의 방향성에 따라 즉각적으로 반응하는 경향이 뚜렷하다. 2021년 GameStop 사태에서 Reddit 커뮤니티가 주가 급등을 촉발한 사례, 특정 인사의 트윗이 암호화폐 가격을 단시간에 급변시킨 사례는 감정이 시장 변동의 핵심 동력으로 작용할 수 있음을 명확히 보여준다 [2]. 특히 COVID-19 이후 정보 확산 속도와 투자 심리의 불안정성은 크게 증가하였으며, 실시간 뉴스나 경제 포럼을 통해 전파되는 감정적 신호가 시장에 민감하게 반영되고 있다. 이러한 환경에서 단순한 가격 중심의 기술적 분석만으로는 시장의 변화를 입체적으로 해석하기 어렵다.

이에 본 연구는 기존 지표가 간과해온 정형 데이터의 계량적 분석력과 비정형 데이터의 질적 해석력을 통합하여 [3], 시장의 실시간 감정변화를 수치로 반영할 수 있는 딥러닝 기반 시장 심리지표(Market Sentiment Index)를 개발하는 것을 목적으로 한다. 나아가 해당 지표를 시각화하고 사용자가 직관적으로 접근할 수 있도록 Flutter 기반 애플리케이션을 구현함으로써 학문적·산업적 활용 가능성을 동시에 확보하고자 한다.

제 2장 관련 연구

제 1절 금융 텍스트 감정 분석과 심리지표 연구 동향

금융 텍스트 분석은 단순한 단어 빈도 분석에서 딥러닝 기반의 문맥 분석으로 발전해 왔다. 초기 연구들은 뉴스 텍스트에서 TF-IDF 등의 통계적 특징을 추출하여 주가 변동을 예측했으나 [4], 이는 단어의 순서나 “상승하지 않았다”와 같은 부정어의 문맥적 의미를 파악하는 데 한계를 보였다. 이를 극복하기 위해서 CNN(Convolutional Neural Network)과 RNN(Recurrent Neural Network)이 도입되었다. 이것들은 문장 전체의 시퀀스 정보를 반영하지 못했고, 초기의 단방향 LSTM 모델도 문장 후반부의 맥락 정보를 전반부 해석에 활용하지 못하는 제약이 있었다.

최근에는 이러한 한계를 해결하기 위해 양방향 LSTM이 표준적인 기법으로 자리를 잡았다 [5]. BiLSTM은 순방향과 역방향의 문맥 정보를 동시에 학습하여 금융 뉴스 특유의 복잡한 문장 구조를 효과적으로 파악한다. 최근 BERT와 같은 대규모 언어 모델(LLM)이 높은 성능을 보이고 있으나, 본 연구와 같이 실시간 데이터 처리와 모바일 환경에서의 경량화가 요구되는 시스템에서는 연산 효율성이 높고 문맥 파악에 특화된 BiLSTM이 여전히 효과적인 대안으로 평가받는다. [6]

기존의 시장 심리지표는 데이터 원천에 따라 정형 데이터 기반과 비정형 데이터 기반으로 나뉜다. VIX(변동성 지수)나 공포·탐욕 지수(Fear and Greed Index)는 가격, 거래량 등 정형 데이터에 의존하여 시장의 수치적 변동성은 잘 보여주지만, 뉴스나 이슈로 인한 투자자들의 정성적인 심리 변화를 선행적으로 포착하지 못한다. 반면, 텍스트 마이닝을 활용한 연구들은 뉴스나 소셜 미디어의 감정을 수치화했으나 [7], 기술적 지표가 주는 시장의 추세 정보를 간과하는 경향이 있었다. 최근 뉴스 감정과 기술적 지표를 결합하려는 시도가 있었으나 [8], 단순히 지표들을 나열하거나 기계적으로 결합하는 수준에 그쳐 각 정보의 중요도를 반영한 가중치 모델링은 미흡했다. 따라서 뉴스 텍스트의 감정(비정형)과 기술적 지표(정형)를 체계적으로 융합한 통합 지표의 필요성이 제기된다.

본 연구는 선행 연구의 한계를 보완하여 다음과 같은 차별점을 갖는다. 첫째, 효율적인 BiLSTM 모델 적용이다. 고비용의 초거대 모델 대신, 금융 뉴스의 문맥 파악에 최적화된 양방향 LSTM을 사용하여 높은 정확도(91.04%)와 모바일 환경에서의 실시간성을 동시에 확보하였다. 둘째, 가중 통합 알고리즘의 제시이다. 뉴스 감정(0.35)과 기술적 지표(0.65)의 단순 결합이 아닌, 각 요소의 시장 영향력을 고려한 가중 평균 방식을 적용하여 지표의 신뢰도를 높였다. 셋째, 실용적 플랫폼 구현이다. 이론적 모델링에 그치지 않고 Flutter 기반의 크로스 플랫폼 애플리케이션을 개발하여, 개인 투자자가 실시간으로 시장 심리를 확인하고 대응할 수 있는 실질적인 도구를 제공하였다.

제 3장 연구 방법

제 1절 데이터셋 구성 및 전처리


본 연구에서는 미국 증시 뉴스 감정 분석을 위한 텍스트 기반 데이터셋을 사용하였으며, 텍스트 열(Text Column)과 감정 라벨 열(Sentiment Column)로 구성되어 있다. 텍스트 열에는 미국 증시 뉴스의 기사 제목 및 내용과 링크가 첨부되어 있으며, 데이터 라벨링은 각 증시 뉴스에 대해 부정(negative, 0), 중립(neutral, 1), 긍정(positive, 2) 세 가지 감정 클래스로 라벨링되어 있다. 텍스트 열은 특수문자 및 불필요한 문자를 제거하는 정제 과정을 거치기 위해서 정규표현식(Regular Expression)을 활용하여 정제 과정을 거쳤다.

항목	값
긍정(positive) 샘플 수	30,510
중립(neutral) 샘플 수	29,215
부정(negative) 샘플 수	17,047
긍정 비율	39.7%
중립 비율	38.1%
부정 비율	22.2%
전체 샘플 수	76,772

[표 1] 데이터셋 라벨링 분포

해당 데이터셋을 검증하기 위해 결측치(missing values)를 확인한 결과, 텍스트 열과 감정 라벨 열 모두 결측치가 없음을 확인하였다. 다음으로, 클래스 분포를 측정하였고 긍정 30,510개(39.7%), 중립 29,215개(38.1%), 부정 17,047개(22.2%)로 결과가 도출되었다. 자세한 통계는 [표 1]에 정리하였다. 이를 통해서 데이터셋의 클래스 분포가 상대적으로 적은 비중을 차지하였다. 향후 데이터 추가 및 증강 데이터 추가로 인한 클래스 불균형이 발생하여 편향된 학습으로 진행되는 것을 방지하기 위해 클래스 가중치(Class Weight Balancing) 기법을 적용하여, 소수 클래스에 더 높은 가중치를 부여하도록 설계했다.

이어서 모델 구현을 위해서 통일된 텍스트 길이가 필요했기 때문에 데이터셋의 텍스트 길이 분포를 측정하였으며, [그림 1]과 [표2]를 통해서 자세한 수치를 확인할 수 있다. 결과적으로, 학습 과정에서 데이터의 손실을 최소화하면서도 계산 효율성을 위해서 약 97% 백분위인 300으로 지정하여 학습을 진행하였다.



[그림 1] 데이터셋 텍스트 길이 분포 히스토그램

통계 지표	원본(단어 수)	토큰화 후 토큰 수
평균 길이	18.36	112.49
중간값	15	97
90% 백분위	34	201
95% 백분위	41	240
약 97% 백분위	-	300
99% 백분위	56	346
최대 길이	303	2,107
최소 길이	1	-

[표 2] 텍스트 길이 분포

제 2절 모델 아키텍처 및 학습 방법

해당 연구에서는 앞에서 언급된 바와 같이 양방향 LSTM(Bidirectional LSTM, BiLSTM) 모델을 채택하였다. 여기서 BERT와 같은 대규모 사전 학습 모델 대신 BiLSTM을 선택한 것은 실제 투자자들에게 실시간으로 제공되어야 하기에 성능과 연산 효율성의 균형을 고려한 결과이다. 제안하는 모델의 상세 아키텍처와 파라미터 구성은 각각 [표 3]와 [표 4]에 제시된 바와 같다.

층 이름	출력 형태	파라미터 수
InputLayer	(None, 300)	0
Embedding	(None, 300, 128)	4,690,560
Bidirectional LSTM	(None, 300, 128)	98,816
GlobalMaxPooling1D	(None, 128)	0
Dense	(None, 64)	8,256
Dropout	(None, 64)	0
Dense	(None, 3)	195
총 파라미터	-	4,797,827
학습 가능한 파라미터	-	4,797,827
비학습 파라미터	-	0

[표 3] 모델 아키텍처 상세 (Batch Size 64 Baseline)

하이퍼파라미터	값
학습률(Learning Rate)	1e-4
최적화 알고리즘	Adam
배치 크기	32, 64, 128, 256
최대 에포크	10
최대 시퀀스 길이	300
손실 함수	sparse_categorical_crossentropy
드롭아웃 비율	0.3

[표 4] 하이퍼파라미터 설정

데이터의 처리 흐름은 다음과 같다. 먼저, 전처리된 텍스트 시퀀스(길이 300)는 Embedding Layer를 통해 128차원의 고차원 벡터 공간으로 매핑된다. 이 과정에서 단어 간의 의미적 유사성이 벡터 거리로 표현되며, 모델은 금융 도메인 특유의 어휘 관계를 학습하게 된다. 임베딩된 벡터는 핵심인 Bidirectional LSTM Layer로 전달된다. 이 층에서는 64개의 유닛이 시퀀스를 양방향으로 스캔하여 각 시점의 은닉 상태(Hidden State)를 결합함으로써, 총 128차원의 전역적인 문맥 정보를 추출한다. 여기서 출력한 시퀀스 정보는 GlobalMaxPooling1D Layer를 통해 고정 길이의 특징 벡터로 변환된다. 평균 풀링(Average Pooling)이 전체적인 정보를 평탄화하는 경향이 있는 반면, 맥스 풀링(Max Pooling)은 문장 내에서 감정을 결정짓는 가장 강력한 핵심 키워드(Signal)를 보존하는 데 유리하다. 추출된 특징은 Dense Layer를 거쳐 추상화되며, 이 과정에서 Dropout(0.3)을 적용하여 특정 뉴런에 대한 과의존을 막고 과적합을 방지하였다. 최종적으로 Output Layer의 Softmax 활성화 함수를 통해 긍정, 중립, 부정의 세 가지 클래스에 대한 확률을 산출한다.

항목	사양
CPU	AMD Ryzen 5600
RAM	32GB
GPU	NVIDIA GeForce RTX 4060 8GB
Python	3.11
TensorFlow	2.15.0
Keras	2.15.0
CUDA	11.8 (cuDNN 8.1.0)
Numpy	1.26.4
Pandas	2.3.0
Scikit-learn	1.7.0

[표 5] 학습 환경

학습 환경은 [표 5]과 같이 TensorFlow 프레임워크와 CUDA 기반의 GPU 환경 속에서 수행되었다. 모델 학습을 위한 최적화 알고리즘으로는 적응적 학습률(Adaptive Learning Rate)을 제공하는 Adam을 사용하여 수렴 속도와 안정성을 확보하였으며, 다중 분류 문제에 적합한 Sparse Categorical Crossentropy를 손실 함수로 사용하였다. 또한, 모델의 일반화 성능을 객관적으로 평가하기 위해 Stratified K-Fold Cross Validation(5-Fold)을 적용하였다. 이는 전체 데이터를 5개 폴드로 나누되, 각 폴드가 전체 데이터의 클래스 분포를 대표하도록 설계하여 평가의 신뢰성을 높이는 방법이다.

배치 크기	총 학습 시간	평균 Fold당 시간
32	약 1시간 14분 (74분)	약 14.8분
64	약 43분	약 8.6분
128	약 28분	약 5.6분
256	약 17분	약 3.4분

[표 6] 배치 크기 별 K-Fold Cross-Validation 학습 시간

마지막으로, 최적의 학습 효율을 찾기 위해 배치 크기(Batch Size)를 32, 64, 128, 256으로 설정하여 비교 실험을 진행하였다. [표 6]에서 확인할 수 있듯이, 배치 크기가 커질수록 연산 병렬화 효율이 높아져 학습 시간은 대폭 단축되었다. 배치 크기 32의 경우 약 74분이 소요된 반면, 배치 크기 256은 약 17분으로 가장 빠른 속도를 보였다. 그러나 배치 크기가 지나치게 크면 일반화 성능(Generalization Performance)이 저하될 우려가 존재하므로, 학습 시간과 예측 성능을 종합적으로 고려하여 최종 배치 크기를 선정하였다.

제 3절 시장 심리지표 산출 방법

시장 심리지표(Market Sentiment Index)는 비정형 데이터인 뉴스 텍스트와 정형 데이터인 기술적 지표를 결합하여 산출된다. 이 과정은 1차 정제(감정 분석)와 2차 정제(지표 통합) 단계로 구분된다. 1차 정제 단계에서는 뉴스 텍스트에 대해 학습된 감정 분석 모델을 적용하여 각 뉴스를 긍정, 중립, 부정으로 분류하고, 일별로 감정 점수를 도출한다.

분류된 감정 결과는 1차 정제 데이터베이스에 저장되고 2차 정제를 위해서 다음의 수식을 통해 정규화된 점수로 변환된다.

$$S_{news} = \frac{pos - neg}{\max(1, pos + neg)}$$

여기서 pos는 해당 일자의 긍정 기사 수, neg는 부정 기사의 수를 의미한다. 분모에 중립 기사를 포함한 전체 기사의 수를 배치하고 최소값을 1로 설정하여, 기사 수가 적을 때 발생할 수 있는 점수 왜곡을 방지하였다. 산출된 점수는 -1(완전 부정)에서 +1(완전 긍정) 사이의 값을 가지며, 중립 기사는 감정의 방향성에는 기여하지 않으나 시장의 관심도를 나타내는 모수로 작용하여 점수의 과도한 쏠림을 완화하는 역할을 한다.

이어서 기술적 지표(RSI, MACD, 이동평균선, VIX)와의 결합을 진행하는데, 각 지표는 서로 다른 척도를 가지므로 통합을 위해서 다음과 같은 기준에 따라 통일된 점수 체계로 변환한다. 첫 번째로, RSI(Relative Strength Index)는 과매수와 과매도 구간을 판단하는 지표로 [9], 14일 기준의 상대 강도를 다음의 수식을 통해 측정한다.

$$RSI = 100 - \frac{100}{1 + RS}, \quad (RS = \frac{\text{평균 상승폭}}{\text{평균 하락폭}})$$

연구에서는 역발상 투자 관점을 적용하여 RSI가 30 이하(과매도)일 경우 +1점, 70 이상(과매수)일 경우 -1점을 부여하고, 그 사이 구간은 선형 보간하여 점수를 산출한다.

두 번째로, MACD이다. MACD는 추세의 전환을 포착하기 위해서 사용되며, 다음의 수식을 통해 측정된다.

$$MACD = EMA_{12} - EMA_{26}$$

12일 지수이동평균(EMA)과 26일 EMA의 차이인 MACD 라인이 신호선(9일 EMA)을 상향 돌파하면 긍정적 신호로, 하향 돌파하면 부정적 신호로 해석하여 점수화한다.

세 번째로, 이동평균선(Moving Average)은 장기 추세를 반영하기 위해 200일 이동평균을 기준으로 하며 다음의 수식을 통해 측정된다.

$$MA_{200} = \frac{1}{200} \sum_{i=0}^{199} P_{t-i}$$

현재 주가가 MA_{200} 대비 10% 이상 높으면 상승 추세로 간주하여 +1점(최대 +2점)을, 10% 이상 낮으면 하락 추세로 간주하여 -1점(최대 -2점)을 부여한다.

네 번째로, VIX는 시장의 공포 심리를 대변한다. VIX 수치가 높으면 높을수록 시장의 불확실성이 크다는 것을 의미하므로, 과거 데이터와 비교하여 수치가 높을수록 부정적인 점수(음수)를 부여하는 역의 관계를 적용하였다.

최종적인 시장 심리지표는 각 요소의 점수(s_i)에 가중치(w_i)를 적용한 가중평균(S)을 구한 뒤, 0~100 사이의 직관적인 수치로 변환하여 산출된다. 산출된 가중 평균 점수 S 는 최종적으로 다음 수식을 통해 0에서 100사이의 인덱스(Index)로 변환된다.

$$S = \sum_i s_i \times \frac{w_i}{W}$$

$$Index = round((S + 2.0) \times 25.0)$$

각 지표별 가중치는 [표 7]에 기재가 되어있다. 뉴스 감정에 가장 높은 가중치를 부여한 이유는 기존 정형 지표가 포착하지 못하는 시장의 미묘한 정성적 분위기를 지표에 적극 반영하기 위함이다.

지표	가중치	선택근거
뉴스 감정	0.35	비정형 데이터의 중요성 반영
RSI	0.15	과매수/과매도 상태 파악
VIX	0.15	시장 변동성 및 공포 지수
MACD	0.15	추세 전환 신호
이동평균	0.20	장기 추세 파악
합계	1.00	-

[표 7] 시장 심리지표 가중치

최종 산출된 지표 값은 시장의 상태를 5단계로 분류하여 해석되며, 상세 범위는 [표 8]에 기재된 바와 같다. 이러한 직관적인 구간 정의를 통해 투자자가 현재의 시장 상황을 즉각적으로 파악하고 의사결정에 활용할 수 있도록 설계하였다.

범위	의미
0-20	위기 (Distressed)
20-40	방어적 (Cautious)
40-60	중립 (Neutral)
60-80	공격적 (Optimistic)
80-100	과열 (Overheated)

[표 8] Market Sentiment Index 범위 설정


제 4장 시스템의 구현

제 1절 시스템 구현 환경

투자자가 실시간으로 시장 심리지표를 확인하고 정보를 공유할 수 있는 통합 플랫폼을 구축하기 위해 Google의 크로스 플랫폼 프레임워크인 Flutter(SDK 3.24.0)와 Dart(3.6.0) 언어를 기반으로 애플리케이션을 구현하였다. Flutter를 채택함으로써 단일 코드베이스로 Android와 IOS 환경에서 네이티브 수준의 성능을 확보하였으며, 위젯 기반의 선언적 UI 구조를 통해 실시간 데이터 시각화에 최적화된 성능을 구현하였다.

시스템의 백엔드 인프라는 데이터의 성격과 요구사항에 따라 Firebase와 Supabase를 혼용하여 구성하였다. 사용자 인증(Authentication), 커뮤니티 게시물 및 프로필 데이터 관리(Firestore), 미디어 파일 저장(Storage)은 Firebase를 활용하여 안정적인 서비스 환경을 구축하였다. 반면, 본 연구의 핵심 데이터인 시장 심리지표와 뉴스 감정 분석 결과는 관계형 데이터베이스 기반의 Supabase(PostgreSQL)에 저장하고 학습된 모델은 Supabase Storage에 압축한 상태로 저장하였다. Supabase의 Realtime Subscription 기능을 통해 서버의 분석 결과가 갱신되는 즉시 클라이언트 애플리케이션에 동기화되도록 설계하였다.

데이터 시각화 및 사용자 경험의 향상을 위해서 다양한 외부 라이브러리를 활용하였다. syncfusion_flutter_gauges 패키지를 사용하여 통합 시장 심리지표(0~100)를 직관적인 반원형 게이지 차트로 표현하였으며, fl_chart를 통해 실시간 주가 변동을 라인 차트로 시각화하였다. 또한 provider 패키지를 통해 애플리케이션의 전역 상태를 효율적으로 관리하였고, shimmer를 이용하여 로딩 전 시각효과를 더했다. 실시간 주가 데이터는 Yahoo Finance API를 통해 수집하여 시각화 모듈에 즉각 반영되도록 구현하였다.



[그림 2] 시스템 아키텍처

더불어, 대용량 딥러닝 모델의 효율적인 관리를 위해 GitHub Actions 기반의 CI/CD 파이프라인을 구축하였다. 학습된 모델은 용량 최적화를 위해 압축된 상태로 저장소에서 관리되며, 배포 단계에서 GitHub Actions 워크플로우가 트리거되어 자동으로 모델 압축을 해제하고 실행 환경에 로드하도록 구성하였다. 이를 통해 모델 업데이트 시 수동 작업을 최소화하고 배포의 안정성을 확보하였다. 본 연구에서 구현된 전체 시스템의 데이터 흐름과 구조는 [그림 2] 시스템 아키텍처에 도식화되어 있다.

제 2절 Flutter 애플리케이션 구현

본 연구에서는 데이터의 성격과 요구사항에 따라 이원화된 데이터베이스 구조를 택했다. 사용자 인증 정보와 커뮤니티 생성 콘텐츠는 문서 지향 NoSQL인 Firebase Firestore와 Storage를 통해 관리하며, 정형화된 시장 심리지표와 뉴스 감정 데이터는 관계형 데이터베이스인 Supabase를 사용하여 관리한다. 사용자 관리 및 커뮤니티 기능은 Firebase 생태계를 활용하여 구현하는데, 인증 체계는 이메일과 비밀번호 방식을 적용하여 검증된 사용자에게만 접근 권한(Token)을 부여한다. 이미지 데이터는 Firebase Storage에 별도로 저장하여 관리 효율성을 높였으며, 해당 파일의 접근 URL만을 Firestore에 저장하는 방식으로 데이터베이스의 경량화를 도모하였다. Firebase 데이터베이스는 크게 사용자 프로필 정보를 관리하는 users 컬렉션과 커뮤니티 게시글을 저장하는 posts 컬렉션으로 구성된다. Firestore의 실시간 동기화 기능을 통해 게시글 생성이나 프로필 업데이트 시 클라이언트 화면에 즉각적으로 반영되도록 설계하였다.

시장 심리지표 산출 결과와 뉴스 감정 분석 데이터는 Supabase를 통해 구조화하여 저장되고 관리된다. 첫 번째로, market_sentiment_index 테이블은 일별 산출된 통합 시장 심리지표와 이를 구성하는 기술적 지표(RSI, VIX, MACD 등)의 수치를 저장한다. 해당 테이블의 상세 구조는 [그림 3]과 같다.

☐	d... d. v	run_at timestamptz v	score int4 v	zone text v
☐	2025-11-18	2025-11-18 01:54:32.041279+00	52	Neutral
☐	2025-11-17	2025-11-17 01:56:11.993078+00	55	Neutral
☐	2025-11-16	2025-11-16 02:00:58.139829+00	48	Neutral
☐	2025-11-15	2025-11-15 01:50:47.033757+00	59	Neutral
☐	2025-11-14	2025-11-14 01:55:07.153704+00	50	Neutral
☐	2025-11-13	2025-11-13 01:56:06.350591+00	54	Neutral
☐	2025-11-12	2025-11-12 01:54:34.696999+00	54	Neutral
☐	2025-11-11	2025-11-11 01:55:33.764809+00	53	Neutral

[그림 3] market_sentiment_index 테이블

두 번째로, news_sentiment 테이블은 실시간으로 수집 및 분석된 뉴스 기사의 본문, 감정 분류 결과, 정확도 등을 저장한다. 해당 테이블의 구조는 위의 [그림 4]에 나타나 있다. 클라이언트 애플리케이션은 데이터의 실시간성을 보장하기 위해 주기적 폴링 방식을 적용하였다. Dart의 Timer 클래스를 활용하여 1초 간격으로 Supabase 쿼리를 요청함으로써, 백엔드에서 갱신되는 최신 시장 심리지표와 뉴스 분석 결과를 사용자 화면에 지연 없이 동기화한다.

☐	i. u...	cr... ti...	text text	perc... flo...	label sentiment_label	sou... t...
☐	1410bf16-85bd-	2025-10-11 10:55	How China Powers Its Electric Cars and High-Speed Trains	0.991544	neutral	finviz
☐	a93e18e9-28a5-	2025-10-11 10:55	Economist warns of uncertainty potentially coming back amid	0.975331	negative	finviz
☐	021371a8-7ae8-	2025-10-11 10:55	Ben Levisohn: This was the week for bubbles	0.741957	negative	finviz
☐	b6709eaa-e103-	2025-10-11 10:55	China Flexed. Trump Hit Back. So Much for the Thaw.	0.688164	negative	finviz
☐	a519b0c0-0a38-	2025-10-11 10:55	The N.B.A. Returns to China After Six Years	0.990336	neutral	finviz
☐	6927ca57-f561-	2025-10-11 10:55	How Churners Earn Money By Regularly Signing Up for Credit	0.859802	neutral	finviz
☐	abdc7931-247a-	2025-10-11 10:55	Behind the Collapse of an Auto-Parts Giant: a \$2 Billion Hole	0.668749	negative	finviz
☐	bf55bfc4-32f5-	2025-10-11 10:55	Rekindling of Tariff Fight Pressures Wall Street's Hottest Trade	0.958791	neutral	finviz
☐	72206b1c-782b-	2025-10-11 10:55	Wall St Week Ahead Investors seek economic clues from ban	0.544466	negative	finviz
☐	b54d0139-a608-	2025-10-11 12:41	Silver Traders Rush Bars to London as Historic Squeeze Rocks	0.922773	negative	finviz
☐	054f5a4b-bdef-	2025-10-11 12:41	Wall St Week Ahead: Investors seek economic clues from ban	0.519569	positive	finviz
☐	f558b166-b769-	2025-10-11 12:41	A Great Year for US Stocks? Not Compared to Rest of the Wo	0.571736	positive	finviz
☐	58ec3869-66c5-	2025-10-11 12:41	Government shutdown wreaks havoc on popular 0% down mo	0.992173	negative	finviz
☐	f6a9b1ac-ee92-	2025-10-11 12:41	Searching for Meaning in the Gold Rally	0.603144	positive	finviz
☐	1ef8d9ff-a88d-<	2025-10-11 12:41	Tariffs hit harder in an economic data vacuum	0.648803	negative	finviz
☐	faa2208c-fafa-<	2025-10-11 15:28	Gold pares gains after brief run above \$4,000/oz on Trump's C	0.89731	positive	finviz
☐	8c3a3359-8e3b-	2025-10-11 15:28	Trump tariffs upend crypto market, trigger record liquidations	0.984136	neutral	finviz

[그림 4] news_sentiment 테이블

애플리케이션 사용자 인터페이스(UI)는 크게 4가지 메인 탭으로 구성되어 있다. 첫 번째로 홈(Home)이다. 시장의 거시적 흐름과 사용자 여론을 동시에 파악할 수 있도록 설계되었다. 상단에는 미국 3대 지수인 S&P 500, NASDAQ, Dow Jones의 실시간 가격 정보와 그래프가 표시된다. Yahoo Finance API를 통해 1분 간격으로 데이터를 비동기 수집하며, fl_chart 라이브러리를 활용하여 인터랙티브한 일일 변동 차트를 시각화하였다. 전일 대비 등락률은 색상을 통해 직관적으로 구분된다. 하단에는 사용자들이 작성한 게시글을 최신순으로 나열하는 리스트를 배치하였다. Firebase Firestore의 실시간 리스너를 통해 데이터베이스 변경 사항을 즉각 반영하며, shimmer 효과를 적


용하여 데이터 로딩 시의 사용자 경험(UX)을 최적화하였다.

두 번째로, 심리지표 탭은 본 연구의 핵심 기능이다. 화면 상단에는 통합 심리지표를 syncfusion_flutter_gauges 라이브러리를 활용하여 반원형 게이지 차트로 표현한다. 지표 점수는 5개 구간으로 구분되어 시각화되며, Supabase와의 1초 단위 동기화를 통해 실시간 시장 상태를 반영한다. 하단에는 지표 산출의 근거가 되는 최근 30건의 뉴스를 리스트 형태로 제공한다. 각 항목은 뉴스 제목과 함께 모델이 예측한 감정 라벨(긍정/중립/부정) 및 확률이 표시되며 추가적으로 어떠한 종류의 기사인지가 표시된다. 또한, 상세 보기 기능에는 ChatGPT API를 통해서 해당 기사의 관련된 내용을 제공 받을 수 있다. 이를 통해서 실제 사용자가 분석 결과에 대해서 직접 판단할 수 있도록 하였다.


세 번째로 작성 탭이다. 사용자가 시장에 대한 의견을 텍스트와 이미지로 업로드할 수 있도록하는 공간이다. 이미지 파일은 대용량 처리에 적합한 Firebase Storage에 비동기적으로 업로드되며, 해당 파일의 접근 URL과 게시글 메타데이터는 Firestore에 저장된다. 업로드 과정 중에는 인디케이터를 통해 진행 상황을 시각적으로 피드백하여 사용성을 높였다. 네 번째로 프로필 탭은 사용자 개인화 정보와 애플리케이션 설정을 관리하는 통합 화면이다. 프로필 사진 수정, 공지사항 확인, 앱 설정, 개발자 피드백 전송 및 로그아웃 기능을 제공하여 사용자가 애플리케이션 환경을 효율적으로 제어할 수 있도록 설계하였다.

제 3절 구현 결과

아래는 연구를 통해 개발된 애플리케이션의 최종 구현 화면이다. [그림 5]와 [그림 6]은 애플리케이션의 홈 탭 실행 화면이다. 화면 상단에는 미국 3대 대표 지수(S&P 500, NASDAQ, Dow Jones)의 실시간 시세와 변동 그래프가 시각화되어 있으며 하단 부에는 사용자 커뮤니티 피드가 위치하며, 프로필 사진, 게시글 이미지 및 내용, 업로드 날짜, 좋아요 및 댓글 기능이 포함된 리스트 뷰(List View) 형태로 구성된 것을 확인할 수 있다.




[그림 5] 홈 탭 화면 1




[그림 6] 홈 탭 화면 2

[그림 7]은 본 시스템의 핵심 기능인 심리지표 및 뉴스 탭 화면이다. 상단에는 2차 정제 과정을 거친 통합 시장 심리지표가 시각화되어 실제 투자자들에게 현재 시장의 심리 상태를 정량적으로 제공한다. 하단에는 1차 정제 데이터인 개별 뉴스 기사의 감정 분석 결과가 카드뷰(Card View) 형식으로 나열된다. [그림 8]은 톨바 우측의 도움말 버튼을 클릭하였을 때 나타나는 바텀 시트(Bottom Sheet) 화면으로, 사용자가 지표를 올바르게 해석할 수 있도록 시장 심리지표의 5단계 구간 기준표를 제공한다.



[그림 7] 뉴스 탭 화면 1



[그림 8] 뉴스 탭 화면 2

[그림 9]는 게시글 작성 탭 화면으로, 사용자가 커뮤니티에 의견과 정보를 공유할 수 있는 상호작용을 제공한다. 해당 화면은 직관적인 UX를 위해 텍스트 입력 필드와

이미지 첨부 버튼, 그리고 최종 업로드 버튼으로 구성되었다. 사용자가 게시글 작성을 완료하면 비동기적으로 데이터가 전송되며, 작업이 성공적으로 완료될 경우 화면 하단에 스낵바(Snackbar)를 출력하여 처리 결과를 즉각적으로 피드백하도록 구현하였다. [그림 10]은 프로필 탭 화면으로, 사용자의 개인화 정보와 애플리케이션의 전반적인 환경을 관리한다. 해당 화면은 계정 설정, 공지사항 확인, 그리고 개발자 피드백 전송의 세 가지 주요 메뉴로 구성되어 있어 사용자가 애플리케이션의 부가 기능을 효율적으로 제어할 수 있도록 설계되었다.




[그림 9] 게시물 탭 화면




[그림 10] 프로필 탭 화면

[그림 11]은 계정 설정 화면으로, 사용자는 이곳에서 자신의 프로필 사진을 수정하거나 로그아웃 기능을 수행할 수 있다. 로그아웃 버튼을 선택하면 현재 세션이 안전하게 종료되고 애플리케이션 초기 로그인 화면으로 전환된다. [그림 12]는 회원가입 화면으로 계정이 없는 신규 사용자는 이곳에서 사용자 이름, 이메일, 비밀번호를 입력하여 계정을 생성할 수 있다. 이때 보안성을 확보하기 위해 비밀번호 입력 필드에는 엄격한 유효성 검사 로직(Validation Check)이 적용되었다. 입력된 비밀번호가 특수문자를 포함하지 않거나 10자리 미만일 경우 가입 절차는 차단되며, 화면 하단에 스낵바를 출력하여 사용자에게 피드백하도록 구현하였다.



[그림 11] 계정 설정 화면



[그림 12] 회원가입 화면

제 5장 연구 결과 및 분석

제 1절 모델 검증 및 평가

모델의 검증 및 평가는 내부, 외부, 동행성 검증으로 나누어 진행하였다. 우선, 모델의 일반화 성능을 확인하기 위해 5-Fold Cross Validation을 적용하였으며, 오분류 패턴을 분석하기 위해서 Confusion Matrix를 활용하였다. 하이퍼파라미터 튜닝의 핵심인 배치크기는 32, 64, 128, 256로 설정하여 비교 실험을 수행하였다. 배치 크기별 상세 성능 지표는 아래의 [표 9]와 [표 10]에 제시된 바와 같다. 실험 결과를 종합적으로 분석한 결과, 배치 크기 64 모델이 평균 검증 정확도(91.04%)와 최고 검증 정확도(91.45%)를 기록하여 가장 우수한 성능을 보였다. 반면, 배치 크기 128과 256은 64에 비해 전반적인 정확도가 다소 하락하는 경향을 나타냈다.

배치 크기	평균 검증 정확도	평균 검증 손실	평균 학습 손실	최고 검증 정확도	최고 Fold
32	0.9075	0.2906	0.1466	0.9123	4
64	0.9104	0.3856	0.0557	0.9145	3
128	0.9077	0.3691	0.0699	0.9112	3
256	0.9056	0.3392	0.1088	0.9100	2

[표 9] 배치 크기별 평균 성능 비교

특히 배치 크기 32와 64 간의 성능 차이에 대한 분석은 다음과 같다. 배치 크기 32 모델은 가장 낮은 검증 손실(0.2906)을 기록하며 학습 데이터에 빠르게 수렴하는 것을 보였다. 그러나 평균 정확도는 64 모델에 비해서 0.29% 낮았으며, Fold 간 성능 편차가 상대적으로 크게 나타났다. [표 11]의 Confusion Matrix를 분석한 결과, 배치 크기 32 모델은 긍정 데이터를 부정으로 오분류하는 비율이 상대적으로 높았다(Fold 1 기준 :402건). 반면에, 배치 크기 64 모델은 검증 손실이 다소 높았으나, 오분류 빈도가 낮고 Fold 간 성능 변동성이 작아 예측의 안정성(Stability) 측면에서 더 우수함을 확인하였다. 이에 본 연구에서는 감정 분류의 정확도와 모델의 안정성을 동시에 확보하기 위해

배치 크기 64를 최적의 파라미터로 선정하였다.

결론적으로 본 연구에서 제안한 Bidirectional LSTM 모델의 최종 성능은 결론적으로 평균 검증 정확도 91.04%, 최고 검증 정확도 91.45%를 달성하였다. 이는 금융 텍스트 감정 분석 분야에서 매우 높은 성능으로, 본 연구에서 제안한 모델이 뉴스 텍스트의 감정을 효과적으로 분류할 수 있음을 입증한다. 특히, Bidirectional LSTM을 활용하여 문장의 전후 문맥을 동시에 고려함으로써, 단방향 LSTM보다 우수한 성능을 달성할 수 있었다

배치 크기	Fold	최종 Epoch	학습 정확도	검증 정확도	학습 손실	검증 손실
32	1	4	0.9516	0.9054	0.1500	0.2928
	2	4	0.9537	0.9084	0.1415	0.2986
	3	4	0.9468	0.9060	0.1678	0.2854
	4	4	0.9523	0.9090	0.1513	0.2862
	5	5	0.9613	0.9087	0.1222	0.2902
평균	-	-	0.9531	0.9075	0.1466	0.2906
64	1	9	0.9821	0.9087	0.0613	0.3797
	2	10	0.9849	0.9105	0.0501	0.3796
	3	10	0.9879	0.9145	0.0406	0.4018
	4	9	0.9828	0.9125	0.0580	0.3948
	5	9	0.9803	0.9059	0.0685	0.3721
평균	-	-	0.9836	0.9104	0.0557	0.3856
128	1	10	0.9792	0.9070	0.0729	0.3540
	2	10	0.9802	0.9032	0.0673	0.3836
	3	10	0.9757	0.9070	0.0809	0.3547
	4	10	0.9803	0.9112	0.0690	0.3547
	5	10	0.9831	0.9100	0.0594	0.3993
평균	-	-	0.9797	0.9077	0.0699	0.3691
256	1	10	0.9700	0.9038	0.0991	0.3506
	2	10	0.9766	0.9099	0.0800	0.3447
	3	10	0.9482	0.8983	0.1734	0.3238
	4	10	0.9699	0.9068	0.1029	0.3325
	5	10	0.9740	0.9095	0.0884	0.3444
평균	-	-	0.9677	0.9056	0.1088	0.3392


[표 10] 배치 크기별 K-Fold Cross Validation 최종 결과

배치 크기	Fold	실제 \ 예측	부정	중립	긍정
32	Fold 1	부정	3072	132	206
		중립	171	5403	269
		긍정	402	273	5427
	Fold 2	부정	2969	142	299
		중립	130	5436	277
		긍정	267	292	5543
	Fold 3	부정	2997	111	301
		중립	164	5346	333
		긍정	317	218	5567
	Fold 4	부정	2998	104	307
		중립	171	5314	358
		긍정	258	199	5645
	Fold 5	부정	3048	100	261
		중립	197	5319	327
		긍정	320	238	5544
64	Fold 1	부정	2860	158	392
		중립	94	5364	385
		긍정	199	288	5615
	Fold 2	부정	3048	97	265
		중립	177	5338	328
		긍정	338	228	5536
	Fold 3	부정	3040	107	262
		중립	156	5430	257
		긍정	349	233	5520
	Fold 4	부정	2906	116	387
		중립	178	5304	361
		긍정	275	245	5582
	Fold 5	부정	2979	124	306
		중립	154	5331	358
		긍정	296	313	5493

[표 11] 배치 사이즈 32, 64 Fold별 Confusion Matrix


제 2절 시장 심리지표 검증

본 연구에서 개발된 시장 심리지표의 유효성을 검증하기 위해 S&P 500 지수와 상관계수를 분석을 수행하였다. 시장 심리지표가 실제 시장 동향을 반영하는지 확인하기 위해, 검증 기간은 2020년 3월 1일부터 6월 1일까지로 설정하였다. 이 기간은 COVID-19 팬데믹 초기로, 시장의 극단적인 공포와 변동성이 지배하던 시기이므로, 본 지표가 변하는 시장 심리를 얼마나 민감하게 반영하는지 검증하기에 적합한 시기이다. 시장 심리지표와 S&P 500 종가의 피어슨 상관관계수(Pearson Correlation Coefficient)를 분석한 결과, 피어슨 상관관계수는 0.888로 나타났다. 이는 매우 높은 양의 상관관계를 의미하며, [그림 13]의 산점도에서 나타나듯 지표의 등락이 실제 지수의 움직임과 밀접하게 연동됨을 시사한다. 추가적으로 통계적 유의성을 검증한 결과, p-value는 $5.09e-25$ 로 0.05보다 현저히 낮게 나타나 두 변수 간의 상관관계가 통계적으로 매우 유의함을 확인하였다.



[그림 13] S&P 500과 시장 심리지표 피어슨 상관관계

다음으로 시장 심리지표가 실제 주가의 등락 방향을 얼마나 정확히 예측하는지 평가하기 위해 동행성(Directional Consistency) 검증을 진행하였다. 2020년 3월 1일부터 2020년 6월 1일까지의 총 101일의 전체 분석 기간 101일 중, 시장의 보합세(변동 폭 $\pm 0.1\%$ 미만)로 인해 방향성을 판단하기 모호한 날을 제외하고, 유의미한 변동이 발생한 53일을 유효 비교 데이터로 선정하였다. 검증 결과, 총 45일간 시장 심리지표의 변화 방향과 S&P 500 지수의 변화 방향이 일치하였다. 상세한 검증 결과는 [그림 14]와 [표 12]에 제시된 바와 같다.



[그림 14] 시장 심리지표와 S&P 500 변화율 동행성 비교

지표	값	비고
전체 분석 기간	101일	2020년 3월 1일 ~ 6월 1일
유효 비교 가능 일수	53일	$\pm 0.1\%$ 미만 변화 제외
동일 방향 일수	45일	시장 심리지표와 S&P500 변화 방향 일치
일치율	84.91%	$(45/53) \times 100$

[표 12] 동행성 검증 결과 요약

분석 결과를 종합하면, 본 지표의 방향 일치율은 84.91%로 매우 높은 수준으로, 시장 심리지표가 시장의 방향성을 매우 잘 예측할 수 있음을 보여준다. 이는 투자자들이 시장 심리지표를 활용하여 시장의 현재 분위기를 가늠하는데 유용할 수 있음을 시사한다. 이처럼 연구에서 개발된 시장 심리지표는 S&P 500 지수와 0.888의 높은 상관관계를 보이며, 84.91%의 방향 일치율을 달성함으로써 투자자가 시장의 현재 분위기를 파악하고 실질적인 의사결정을 내리는 데 기여할 수 있는 유용한 도구임이 입증되었다.

제 6장 결론 및 향후 과제

제 1절 결론

본 연구에서는 딥러닝 기반 감정 분석 모델을 활용하여 미국 증시 뉴스의 비정형 데이터를 분석하고, 이를 정형화된 기술적 지표와 결합하여 통합 시장 심리지표(Market Sentiment Index)를 개발하였다. 핵심 알고리즘인 감정 분석 모델은 문장의 전후 문맥을 동시에 학습하는 Bidirectional LSTM 구조를 채택하여, 단방향 LSTM 대비 향상된 문맥 파악 능력과 분류 성능을 확보하였다. 나아가, 실제 투자자들이 시공간의 제약 없이 지표에 접근할 수 있도록 Flutter 기반의 모바일 커뮤니티 애플리케이션을 구현하여 시스템의 실용성을 극대화하였다.

모델 및 지표의 성능 검증 결과는 다음과 같다. 5-Fold Cross Validation을 수행한 결과, 배치 크기 64에서 평균 91.04%, 최고 91.45%의 검증 정확도를 기록하여 금융 텍스트 분석 분야에 우수한 성능을 입증하였다. 개발된 시장 심리지표(뉴스 감정, RSI, VIX, MACD, 이동평균선)의 유효성 검증에서는 S&P 500지수와 0.888의 강한 양의 상관관계($p\text{-value} : 5.09 \times 10^{-25}$)를 확인하였으며, 84.91%의 동행성 일치율을 달성하여 시장의 정서적 흐름을 효과적으로 반영함을 증명하였다.

본 연구의 학문적 기여와 실용적 기여는 다음과 같다. 첫 번째, 뉴스 텍스트와 기술적 지표를 가중 통합하여 시장 심리를 입체적으로 수치화하는 새로운 방법론을 제시하였다. 두 번째, BiLSTM 모델에 클래스 가중치(Class Weight) 기법과 최적화된 하이퍼파라미터를 적용하여, 데이터 불균형 문제를 완화하고 일반화된 성능을 확보하였다. 세 번째, 실시간 데이터 파이프라인과 크로스 플랫폼 애플리케이션을 구축하여, 본 연구의 결과물이 단순한 이론적 모델링에 그치지 않고 실제 투자 의사결정 지원 도구로 활용될 수 있는 실용적 가능성을 실증하였다.

제 2절 향후 과제

본 연구의 한계를 보완하고 시스템을 더욱 발전시키기 위한 향후 연구 방향은 데이터 검증 방법론의 고도화, 모델 성능 개선, 그리고 적용 범위의 확장 측면에서 다음과 같이 제시된다.

첫 번째 시계열 데이터 특성을 반영한 검증 방법론의 도입이다. 본 연구에서는 데이터 클래스 불균형 해소를 우선시하여 Stratified K-Fold를 적용하였으나, 이는 시계열 데이터의 시간적 순서를 고려하지 못해 미래의 정보가 학습에 반영되는 선견 편향(Look-ahead Bias)의 가능성이 존재한다. 향후 연구에서는 Time Series Split 혹은, Walk-Forward Validation 기법을 적용하여 과거 데이터로만 학습하고 미래 데이터를 예측하는 엄격한 검증 체계를 구축해야 한다. 두 번째로, 가중치 산출의 통계적 최적화이다. 현재의 시장 심리지표는 실험적 경험에 기반하여 뉴스 감정과 기술적 지표의 가중치를 설정하였다. 이를 보완하기 위해서 그리드 서치(Grid Search)나 유전 알고리즘(Genetic Algorithm)을 도입하여, 실제 시장 지수와의 오차를 최소화하는 최적의 가중치 조합을 수학적으로 산출하는 연구가 필요하다. 또한, 상관관계 분석 시 단순 종가를 넘어 추세 성분을 제거한 수익률 간의 상관분석을 수행하여 지표의 신뢰도를 높여야 한다.

세 번째로 금융 특화 언어 모델의 도입이다. 금융 도메인의 방대한 텍스트로 사전 학습된 FinBERT를 적용한다면 금융 뉴스 특유의 복잡한 문맥과 미묘한 감정선을 더욱 정교하게 포착할 수 있을 것이다. 네 번째로 데이터 소스 확장 및 품질 관리이다. 뉴스 데이터뿐만 아니라 X, Reddit 등 소셜 미디어 데이터를 통합하여 시장의 즉각적인 여론을 반영할 필요가 있다.

마지막으로, 적용 시장의 다변화 및 장기적인 검증이다. 현재 미국 증시(S&P 500) 중심 모델을 한국, 유럽 등 타 국가의 금융 시장이나, 비트코인 및 채권 시장과 같은 다양한 자산군으로 확장하여 모델의 범용성(Generalization)을 검증해야 한다. 또한, 수년간의 장기 시계열 데이터를 확보하여 다양한 시장 사이클(강세장, 약세장, 횡보장)에서

의 지표 안정성을 지속적으로 평가함으로써, 본 플랫폼을 더욱 신뢰할 수 있는 투자 의사결정 지원 시스템으로 발전시켜 나갈 것이다.

참 고 문 헌

- [1] P. C. Tetlock, "Giving Content to Investor Sentiment: The Role of Media in the Stock Market," *The Journal of Finance*, vol. 62, no. 3, pp. 1139 - 1168, Jun. 2007.
- [2] M. Baker and J. Wurgler, "Investor Sentiment and the Cross-Section of Stock Returns," *The Journal of Finance*, vol. 61, no. 4, pp. 1645 - 1680, Aug. 2006.
- [3] Kim, Sunghyun, Chang, Sokho, and Lee, Sangwon, "Consumer Trend Platform Development for Combination Analysis of Structured and Unstructured Big Data," *Journal of Digital Convergence*, vol. 15, no. 6, pp. 133 - 143, Jun. 2017.
- [4] Y. M. Kim and S. J. Jeong, "A Study on Stock Price Prediction Model based on Sentiment Analysis using News Big Data," *Journal of Intelligence and Information Systems*, vol. 26, no. 3, pp. 21-41, 2020.
- [5] M. Schuster and K. K. Paliwal, "Bidirectional recurrent neural networks," *IEEE Transactions on Signal Processing*, vol. 45, no. 11, pp. 2673 - 2681, Nov. 1997.
- [6] T. Fischer and C. Krauss, "Deep learning with long short-term memory networks for financial market predictions," *European Journal of Operational Research*, vol. 270, no. 2, pp. 654 - 669, Oct. 2018.
- [7] Yoon Sun Lee, Ju-Hong Lee, Bum Ghi Choi and Jae Won Song, "MPIL: Market prediction through image learning of unstructured and structured data," *Smart Media Journal*, vol. 10, no. 2, pp. 16-21, 2021.
- [8] M. R. Vargas, B. S. L. P. de Lima, and A. G. Evsukoff, "Deep learning for stock market prediction from financial news articles," in *2017 IEEE International Conference on Computational Intelligence and Virtual Environments for Measurement Systems and Applications (CIVEMSA)*, Annecy, France, 2017, pp. 60 - 65.
- [9] J. W. Wilder, *New Concepts in Technical Trading Systems*. Greensboro, NC, USA: Trend Research, 1978.